

UNIVERSIDAD JUÁREZ AUTÓNOMA DE TABASCO
División Académica de Ciencias Básicas

PROYECTO DE ESTADÍSTICA NO PARAMETRICA
Pruebas de Bondad de Ajuste, Rangos y Contingencia

Asignatura: Demografía
Profesor: Dr. David Josafat Santana Cobian

Estudiante:
Pablo Abdel León Evia

Fecha: 10 de Junio de 2026

Funciones y variables

Declaramos el nivel de significancia:

```
alpha = 0.05
```

Programando la función de lilliefors para probar que una muestra proviene de una distribución exponencial.

```
lilliefors.exp.test <- function(x){  
  n <- length(x)  
  i <- 1:n  
  xi <- sort(x)  
  zi <- xi / mean(x)  
  fi <- 1 - exp(-zi)  
  t1 <- (i / n) - fi  
  t2 <- fi - ((i - 1)/n)  
  D <- max(abs(t1),abs(t2))  
  return(D)  
}
```

Definimos la función de la prueba Ji- cuadrada, las entradas son las muestras, el tipo de distribución y el tipo de parámetros, aplicamos la aplicación de fórmula de Sturges para estimar la cantidad de categorías.

```
chisq.test <- function(x, p_dist_func, num_param, ...) {  
  n <- length(x)  
  
  # 1. Determinación de intervalos (Sturges)  
  k <- floor(1 + log2(n))  
  
  # Dividimos los tramos  
  cortes <- quantile(x, probs = seq(0, 1, length.out = k + 1))  
  cortes[1] <- -Inf  
  cortes[length(cortes)] <- Inf  
  
  # 3. Frecuencias Observadas (O_i)  
  O_i <- as.vector(table(cut(x, breaks = cortes, include.lowest = TRUE)))  
  
  # 4. Frecuencias Esperadas (E_i)  
  p_acumulada <- p_dist_func(cortes, ...)  
  prob_intervalo <- diff(p_acumulada)  
  prob_intervalo <- prob_intervalo / sum(prob_intervalo) #Normalizamos  
  E_i <- n * prob_intervalo  
  
  # 5. Cálculo del Estadístico de Prueba  
  estadistico <- sum(((O_i - E_i)^2) / E_i)  
  
  # 6. Grados de Libertad y Decisión Teóricas  
  df_corregidos <- k - 1 - num_param  
  punto_critico <- qchisq(1 - alpha, df = df_corregidos)  
  p_valor <- 1 - pchisq(estadistico, df = df_corregidos)
```

Los grados de libertad de la Ji cuadrada es $k - 1 - r$, debido a que se estiman los parámetros, la salida de la función es el estadístico de prueba, los intervalos, los grados de libertad de la ji-cuadrada, el punto crítico y el valor del p-value.

```
# Retornamos los resultados  
return(list(  
  statistic = estadistico,  
  intervals = k,  
  df = df_corregidos,  
  critical_value = punto_critico,  
  p.value = p_valor  
))  
}
```

Para la prueba de Anderson-Darling se ocupó una aproximación, debido a la complejidad de la prueba, se recurrió a un ajuste para reducir el error tipo II, $p_{teorico}$ se definió, debido al estadístico de prueba que ocupa logaritmos, para evitar una indeterminación de $\ln(0)$ o $\ln(1)$, las entradas de la función son iguales que la prueba ji-cuadrada anterior pero en el calculo del p-value y del punto crítico se aproxima a partir de la aproximación por el método de Monte Carlo con 10000 simulaciones, el calculo del punto crítico es si definimos a la función A, calculamos el cuantil número .95, donde el valor es el punto crítico y el valor del p-value es $P(A \geq x) = p_value$

```
ad.test <- function(x, p_dist_func, ...) {
  n <- length(x)
  i <- 1:n

  # 1. Ordenamos los datos de menor a mayor (Requisito estricto de la prueba)
  x_sort <- sort(x)

  # 2. Calculamos las probabilidades acumuladas teóricas (U_i)
  p_teorica <- p_dist_func(x_sort, ...)

  # Control de estabilidad numérica para evitar la indeterminación de ln(0) o ln(1)
  p_teorica <- pmax(pmin(p_teorica, 1 - 1e-10), 1e-10)

  # 3. Vector invertido para el extremo superior: U_(n-i+1)
  p_teorica_rev <- rev(p_teorica)

  # 4. Aplicamos la sumatoria de la fórmula analítica de Anderson-Darling
  sumatoria <- (2 * i - 1) * (log(p_teorica) + log(1 - p_teorica_rev))
  A2_estadistico <- -n - (1 / n) * sum(sumatoria)

  # 5. Corrección para muestras finitas (A_modificado)
  A2_modificado <- A2_estadistico * (1 + 0.75/n + 2.25/(n^2))

  return(list(
    statistic = A2_estadistico,
    adjusted_statistic = A2_modificado
  ))
}
```

Para la prueba de Kolmogorov-Smirnov, los parámetros de la ks.test tiene las mismas entradas que las pruebas anteriores

```
ks.test <- function(x, p_dist_func, ...) {
  n <- length(x)

  # Ordenamos los datos
  x_sort <- sort(x)

  # Creamos dos vectores 0 de dimensión n
  d_mas <- numeric(n)
  d_menos <- numeric(n)

  # Ciclo FOR para recorrer y restar cada escalón individualmente
  for(i in 1:n) {
    # Probabilidad teórica acumulada para el dato actual F0(x_i)
    p_teorica <- p_dist_func(x_sort[i], ...)

    # Escalón superior: (i / n) - F0(x_i)
    d_mas[i] <- (i / n) - p_teorica

    # Escalón inferior: F0(x_i) - ((i - 1) / n)
    d_menos[i] <- p_teorica - ((i - 1) / n)
  }

  # El estadístico final es el máximo absoluto observado en toda la muestra
  max_d_mas <- max(abs(d_mas))
  max_d_menos <- max(abs(d_menos))
  D_estadistico <- max(max_d_mas, max_d_menos)

  # Cálculo del p-value (Aproximación Asintótica + Corrección)
  d_corregido <- D_estadistico + (1 / (6 * n)) + (D_estadistico / (2 * n))
}
```

Aproximamos el cálculo del p_value a partir de la distribución asintótica, pero para reducir el error tipo II, ajustamos la prueba, el nombre técnico exacto de esa línea es la **fórmula de ajuste de Stephens para la probabilidad límite de la estadística D**.

La función de distribución asintótica ($n \rightarrow \infty$) de $\sqrt{n}D^+$ y $\sqrt{n}D^-$ está dada por

$$H(x) = \lim_{n \rightarrow \infty} G\left(\frac{x}{\sqrt{n}}\right) = 1 - e^{-2x^2}$$

```
# Retornamos la lista con todos los valores calculados
return(list(
  statistic = D_estadistico,
  p.value   = p_value
))
}
```

La salida es el estadístico de prueba y el cálculo del p_value.

La prueba de Shapiro-Wilk se basa en probar normalidad, tiene una pequeña modificación, la entrada no es simplemente los datos, “reescalo” los datos con el tipo de distribución, porque la prueba sería inservible o en vano, debido al comportamiento de los datos (Heavy Tail), la modificación es otra forma de ajustar distribuciones que no sea una normal.

```
shapiro.test <- function(x) {
  n <- length(x)

  # Ordenar los datos (eje Y del gráfico Q-Q)
  y <- sort(x)

  # Calcular los cuantiles teóricos normales esperados (eje X del gráfico Q-Q)
  probabilidades <- (1:n - 0.375) / (n + 0.25)
  x_teorica <- qnorm(probabilidades)

  # El estadístico W es el coeficiente de correlación al cuadrado (R^2)
  W_estadistico <- cor(x_teorica, y)^2

  # P-value
  mu_sencilla <- -1.58 - (0.31 * log(n))
  sigma_sencilla <- exp(-0.48 + (0.43 * log(n)))

  z <- (log(1 - W_estadistico) - mu_sencilla) / sigma_sencilla
  p_value <- pnorm(z, lower.tail = FALSE)

  # Retornar resultados
  return(list(
    statistic = W_estadistico,
    p.value   = p_value
  ))
}
```

Después de las 5 pruebas de ajustes de bondad, se definieron otras funciones para estimar los parámetros de las distribuciones a partir de los datos, se usaron estimaciones como el método de máxima verosimilitud, método de momentos y una aproximación a los parámetros de una distribución Weibull debido a la incapacidad de tener expresiones de los parámetros de una manera sencilla a partir de aproximación de Newton-Raphson.

Estimación de los parámetros de una dist. Gamma por MMV.

```
# =====
# Gamma por Máximo Verosimilitud fórmula de CHOI-WETTE
# =====
estimar_gamma_mle <- function(datos) {
  M <- log(mean(datos)) - mean(log(datos))
  shape_mle <- (3 - M + sqrt((M - 3)^2 + 24 * M)) / (12 * M)
  rate_mle <- shape_mle / mean(datos)
  return(c(shape = shape_mle, rate = rate_mle))
}

# =====
# Weibull por Newton-Rhapson
# =====
estimar_weibull_mle <- function(datos, tolerancia = 1e-6) {
  k_actual <- 1.0
  error <- 1

  while (error > tolerancia) {
    sum_k <- sum(datos^k_actual)
    sum_ln <- sum(datos^k_actual * log(datos))
    sum_ln2 <- sum(datos^k_actual * (log(datos))^2)

    f_k <- (sum_ln / sum_k) - (1 / k_actual) - mean(log(datos))
    df_k <- ((sum_ln2 * sum_k) - (sum_ln)^2) / (sum_k)^2 + (1 / k_actual^2)

    k_anterior <- k_actual
    k_actual <- k_anterior - (f_k / df_k)
    error <- abs(k_actual - k_anterior)
  }

  shape_mle <- k_actual
  scale_mle <- (mean(datos^shape_mle))^(1 / shape_mle)

  return(c(shape = shape_mle, scale = scale_mle))
}
```

Estimamos los parámetros de una distribución LogNormal a partir del MMV.

```
# =====
# lognormal Máximo Verosimilitud
# =====
estimar_lognormal_mle <- function(datos) {
  n <- length(datos)
  datos_log <- log(datos)

  meanlog_mle <- mean(datos_log)

  var_mle <- var(datos_log) * ((n - 1) / n)
  sdlog_mle <- sqrt(var_mle)

  return(c(meanlog = meanlog_mle, sdlog = sdlog_mle))
}
```

Estimación de los parámetros de una distribución Beta, las entradas de la función tienen que estar reescaladas (0,1).

```
# =====
# Beta por método de momentos
# =====
estimar_beta_mle <- function(datos) {
  datos_escalados <- datos

  x_bar <- mean(datos_escalados)
  v_bar <- var(datos_escalados)

  factor <- (x_bar * (1 - x_bar) / v_bar) - 1

  shape1_mle <- x_bar * factor
  shape2_mle <- (1 - x_bar) * factor

  if(shape1_mle <= 0) shape1_mle <- 0.1
  if(shape2_mle <= 0) shape2_mle <- 0.1

  return(c(shape1 = shape1_mle, shape2 = shape2_mle))
}
```

Se aproximan los parámetros por el Método Newton-Raphson, la tolerancia es de 0.000001 de error.

```
# =====
# Weibull por Newton-Raphson
# =====
estimar_weibull_mle <- function(datos, tolerancia = 1e-6) {
  k_actual <- 1.0
  error <- 1

  while (error > tolerancia) {
    sum_k <- sum(datos^k_actual)
    sum_ln <- sum(datos^k_actual * log(datos))
    sum_ln2 <- sum(datos^k_actual * (log(datos))^2)

    f_k <- (sum_ln / sum_k) - (1 / k_actual) - mean(log(datos))
    df_k <- ((sum_ln2 * sum_k) - (sum_ln)^2) / (sum_k)^2 + (1 / k_actual^2)

    k_anterior <- k_actual
    k_actual <- k_anterior - (f_k / df_k)
    error <- abs(k_actual - k_anterior)
  }

  shape_mle <- k_actual
  scale_mle <- (mean(datos^shape_mle))^(1 / shape_mle)

  return(c(shape = shape_mle, scale = scale_mle))
}
```

Pruebas estadísticas

Monto total de reclamaciones de un seguro de automóviles

1. Contexto:

El presente análisis se realiza utilizando el conjunto de datos de reclamaciones y pólizas de seguros de automóviles. Específicamente, se extrae y evalúa la variable aleatoria continua X , que representa el Monto Total de la Reclamación (Total.Claim.Amount).

Se dispone de una muestra aleatoria independiente extraída de la base de datos institucional, cuyo tamaño muestral es $n_1 = 9134$

2. Pregunta de Investigación:


¿Existe suficiente evidencia estadística para determinar si una distribución de probabilidad teórica continua de la familia de escalas y formas, específicamente


la distribución Weibull o la distribución Gamma, modela de manera óptima el comportamiento de la severidad de las reclamaciones de seguros de autos, permitiendo simultáneamente descartar un ajuste Exponencial puro?

3. Pruebas de Bondad de Ajuste Aplicadas:

- Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson
- Prueba de Lilliefors para exponencial
- Prueba de Kolmogorov-Smirnov (KS)
- Prueba de Anderson-Darling (AD)
- Prueba de Shapiro-Wilk (SW)

4. Gráficos de Ayuda:





5. Hipótesis nula y alternativa en forma conceptual:

1. Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son Gamma y Weibull con parámetros estimados.

2. Prueba de Lilliefors

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ es una exponencial con parámetro estimado.

3. Prueba de Kolmogorov-Smirnov

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son Gamma y Weibull con parámetros estimados.

4. Prueba de Anderson-Darling

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son Gamma y Weibull con parámetros estimados.

5. Prueba de Shapiro-Wilk

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ se distribuye de una $N(0,1)$ con datos escalados con distribución Gamma y Weibull con parámetros estimados.

6. Estadísticos de Prueba, Región de Rechazo y p-values

Para cada contraste se establece un nivel de significancia estándar (95% de confianza). La regla de decisión consiste en rechazar la hipótesis nula (H_0) si el

estadístico de prueba calculado supera el punto crítico teórico, o de manera equivalente, si el p-value es menor a 0.05.

A) Análisis Bajo la Distribución Teórica Weibull

- **Prueba Ji-Cuadrada de Pearson:**

- Estadístico de prueba: 1405.248
- Valor crítico: 19.675
- Criterio de decisión: Se rechaza H_0 si $T \in [19.675, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto indica que las frecuencias observadas en el portafolio de seguros difieren significativamente de las frecuencias esperadas bajo un modelo teórico Weibull, lo que significa que de manera global la distribución no logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos.

- **Prueba de Kolmogorov-Smirnov:**

- Estadístico de prueba: 0.1052158
- Valor crítico: 0.01274418
- Criterio de decisión: Se rechaza H_0 si $T \in [0.01274418, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distancia máxima absoluta observada en el portafolio de seguros difiere significativamente de la curva acumulada esperada bajo un modelo teórico Weibull, lo que significa que de manera global la distribución no logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos.

- **Prueba de Anderson-Darling:**

- Estadístico de prueba: 82.568
- Valor crítico: 2.453
- Criterio de decisión: Se rechaza H_0 si $T \in [2.453, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que las discrepancias

cuadráticas ponderadas en el portafolio de seguros difieren significativamente de las colas esperadas bajo un modelo teórico Weibull, lo que significa que de manera global la distribución no logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos.

- **Prueba de Shapiro-Wilk (Cuantiles Transformados):**

- Estadístico de prueba: 0.9751756
- Valor crítico: 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.4909168$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distribución de los cuantiles inversos normales en el portafolio de seguros no difiere significativamente de la linealidad esperada bajo un modelo teórico Weibull, lo que significa que de manera global la distribución logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos bajo esta transformación.

B) Análisis Bajo la Distribución Teórica Gamma

- **Prueba Ji-Cuadrada de Pearson:**

- Estadístico de prueba: 1641.065
- Valor crítico: 19.67514
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que las frecuencias observadas en el portafolio de seguros difieren significativamente de las frecuencias esperadas bajo un modelo teórico Gamma, lo que significa que de manera global la distribución no logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos.

- **Prueba de Kolmogorov-Smirnov:**

- Estadístico de prueba: 0.125731
- Valor crítico: 0.01274418
- Criterio de decisión: Se rechaza H_0 si $T \in [0.01274418, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distancia máxima absoluta observada en el portafolio de seguros difiere significativamente de la curva acumulada esperada bajo un modelo teórico Gamma, lo que significa que de manera global la distribución no logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos.

- **Prueba de Anderson-Darling:**

- Estadístico de prueba: 120.851
- Valor crítico: 2.453
- Criterio de decisión: Se rechaza H_0 si $T \in [2.453, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que las discrepancias cuadráticas ponderadas en el portafolio de seguros difieren significativamente de las colas esperadas bajo un modelo teórico Gamma, lo que significa que de manera global la distribución no logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos.

- **Prueba de Shapiro-Wilk (Cuantiles Transformados):**

- Estadístico de prueba: 0.9643167
- Valor crítico: 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.486284$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distribución de los cuantiles inversos normales en el portafolio de seguros no difiere significativamente de la linealidad esperada bajo un modelo teórico Gamma, lo que significa que de manera global la distribución logra agrupar perfectamente el comportamiento de los montos de reclamación en todos sus intervalos bajo esta transformación.

C) Análisis Bajo la Distribución Teórica Exponencial

- **Prueba de Lilliefors:**

- Estadístico de prueba: 0.2191
- Valor crítico: 0.0112

- Criterio de decisión: Se rechaza H_0 si $T \in [0.0112, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con un nivel de confianza del 95%, para rechazar la hipótesis nula. El estadístico calculado supera drásticamente el punto crítico, por lo que se concluye que el supuesto de una severidad de reclamaciones con comportamiento exponencial puro queda totalmente descartado para este portafolio de seguros.

Base de datos de salarios de Ingenieros en Software

1. Contexto:

Para este análisis usamos una base de datos real sobre sueldos en el sector tecnológico. La variable que estamos estudiando es el sueldo de los ingenieros de software (Salary).

El tamaño de nuestra muestra es $n_2 = 22774$, después de haber limpiado y suavizado un dato atípico bastante raro que encontramos en la fila 18640 para que no nos alterara los resultados.




2. Pregunta de Investigación

¿Los datos de los salarios de los ingenieros de software se adaptan bien a un modelo teórico de la familia de formas y escalas, como la distribución Weibull o la Log-Normal, o de plano podemos descartar que sigan un comportamiento Exponencial puro?

3. Pruebas de Bondad de Ajuste Aplicadas:

- Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson
- Prueba de Lilliefors para exponencial
- Prueba de Kolmogorov-Smirnov (KS)
- Prueba de Anderson-Darling (AD)
- Prueba de Shapiro-Wilk (SW)

4. Gráficos de Ayuda



5. Hipótesis nula y alternativa en forma conceptual:

1. Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Weibull con parámetros estimados.

2. Prueba de Lilliefors

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ es una exponencial con parámetro estimado.

3. Prueba de Kolmogorov-Smirnov

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Weibull con parámetros estimados.

4. Prueba de Anderson-Darling

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Weibull con parámetros estimados.

5. Prueba de Shapiro-Wilk

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ se distribuye de una $N(0,1)$ con datos escalados con distribución LogNormal y Weibull con parámetros estimados.

6. Resultados y Conclusiones

Para cada contraste se establece un nivel de significancia estándar (95% de confianza). La regla de decisión consiste en rechazar la hipótesis nula (H_0) si el estadístico de prueba calculado supera el punto crítico teórico, o de manera equivalente, si el p-value es menor a 0.05.

A) Análisis Bajo la Distribución Teórica Log-Normal

Prueba de Ji-Cuadrada:

- Estadístico de prueba: 1480.101
- Valor crítico: 21.02607
- Criterio de decisión: Se rechaza H_0 si $T \in [21.02607, \infty)$
- $p - \text{value} = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto indica que los datos del monto total de las reclamaciones de seguros de automóviles no se ajustan a esta distribución bajo el análisis de frecuencias por intervalos.

Prueba de Kolmogorov-Smirnov:

- Estadístico de prueba: 0.04242359
- Valor crítico: 0.008075801
- Criterio de decisión: Se rechaza H_0 si $T \in [0.008075801, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto indica que la distancia máxima observada es demasiado grande, por lo tanto, los datos del monto total de las reclamaciones de seguros de automóviles no se ajustan a esta distribución de manera general.

Prueba de Anderson-Darling:

- Estadístico de prueba: 35.23662
- Valor crítico: 2.5057
- Criterio de decisión: Se rechaza H_0 si $T \in [2.5057, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto indica que, al evaluar de forma estricta los extremos de la muestra, los datos del monto total de las reclamaciones de seguros de automóviles no se ajustan a esta distribución teórica.

Prueba de Shapiro-Wilk:

- Estadístico de prueba: 0.994315
- Valor crítico: 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0$
- **Conclusión:** No existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto indica que, tras aplicar una transformación matemática a los valores, los datos del monto total de las reclamaciones de seguros de automóviles se ajusta de manera lineal a la distribución Lognormal.

B) Análisis Bajo la Distribución Teórica Weibull

Prueba de Ji-Cuadrada:

- Estadístico de prueba: 3342.457
- Valor crítico: 21.02607
- Criterio de decisión: Se rechaza H_0 si $T \in [21.02607, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto indica que la distribución por intervalos de los datos del monto total de las reclamaciones de seguros de automóviles no se ajusta a la distribución Weibull.

Prueba de Kolmogorov-Smirnov:

- Estadístico de prueba: 0.08428185
- Valor crítico: 0.008075801
- Criterio de decisión: Se rechaza H_0 si $T \in [0.008075801, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto demuestra que la forma acumulada general de los datos del monto total de las reclamaciones de seguros de automóviles no se ajusta a la distribución Weibull.

Prueba de Anderson-Darling:

- Estadístico de prueba: 224.6944
- Valor crítico: 2.5057
- Criterio de decisión: Se rechaza H_0 si $T \in [2.5057, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto confirma que, especialmente en las reclamaciones de montos más altos y más bajos, los datos del monto total de las reclamaciones de seguros de automóviles no se ajustan a la distribución Weibull.

Prueba de Shapiro-Wilk:

- Estadístico de prueba : 0.955097
- Valor crítico : 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.4863167$

Conclusión: No existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Esto indica que, utilizando la escala de transformación de cuantiles, la tendencia de los datos del monto total de las reclamaciones de seguros de automóviles sí se ajusta a la distribución Weibull de forma aceptable.

C) Análisis Bajo la Distribución Teórica Exponencial

Prueba de Lilliefors:

- Estadístico de prueba: 0.1372273

- Valor crítico: 0.007125412
- Criterio de decisión: Se rechaza H_0 si $T \in [0.007125412, \infty)$
- $p - value = 2.870955 * 10^{-95}$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95% para rechazar la hipótesis nula. Debido a que el error de ajuste calculado supera drásticamente el límite permitido, se concluye firmemente que los datos del monto total de las reclamaciones de seguros de automóviles no se ajustan a una distribución Exponencial pura.

Variación porcentual anual del Producto Interno Bruto (PIB)

1. Contexto:

El presente análisis se realiza utilizando datos oficiales de la variación porcentual anual del Producto Interno Bruto (PIB) del estado de Tabasco para el periodo comprendido entre 2004 y 2024. La variable bajo estudio es la tasa de crecimiento económico anual.

Se dispone de una muestra de tasas de crecimiento, a la cual se le aplicó una transformación por desplazamiento (sumando el valor absoluto del mínimo más 0.5) para garantizar que todos los valores sean positivos, permitiendo así el ajuste de distribuciones como la Log-Normal y la Weibull. El tamaño muestral es $n_3 = 21$




2. Pregunta de Investigación:

¿Existe suficiente evidencia estadística para determinar que la variación porcentual anual del PIB de Tabasco se comporta según un modelo teórico de la familia de formas y escalas, específicamente la distribución Log-Normal o la Weibull, permitiendo al mismo tiempo descartar un comportamiento Exponencial puro?

3. Pruebas de Bondad de Ajuste Aplicadas:

- Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson
- Prueba de Lilliefors para exponencial
- Prueba de Kolmogorov-Smirnov (KS)
- Prueba de Anderson-Darling (AD)
- Prueba de Shapiro-Wilk (SW)

4. Gráficos de Ayuda



5. Hipótesis nula y alternativa:

1. Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Weibull con parámetros estimados.

2. Prueba de Lilliefors

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ es una exponencial con parámetro estimado.

3. Prueba de Kolmogorov-Smirnov

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Weibull con parámetros estimados.

4. Prueba de Anderson-Darling

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Weibull con parámetros estimados.

5. Prueba de Shapiro-Wilk

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ se distribuye de una $N(0,1)$ con datos escalados con distribución LogNormal y Weibull con parámetros estimados.

6. Estadísticos de Prueba, Región de Rechazo y p-values

Para cada contraste se establece un nivel de significancia estándar $\alpha = 0.05$ (95% de confianza). La regla de decisión consiste en rechazar la hipótesis nula (H_0) si el estadístico de prueba calculado supera el punto crítico teórico, o de manera equivalente, si el p-value es menor a 0.05.

A) Análisis Bajo la Distribución Teórica Log-Normal

Prueba Ji-Cuadrada de Pearson:

- Estadístico de prueba: 29.76714
- Punto crítico: 5.991465
- Criterio de decisión: Se rechaza H_0 si $T \in [5.991465, \infty)$
- $p - \text{value} = 3.436754 * 10^{-7}$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Esto indica que las frecuencias observadas de las tasas de crecimiento del PIB difieren significativamente de las frecuencias esperadas bajo un modelo teórico Log-Normal, lo que significa que, de manera

global, la distribución no logra agrupar perfectamente el comportamiento de la variación del PIB en todos sus intervalos.

Prueba de Kolmogorov-Smirnov:

- Estadístico de prueba: 0.2413028
- Punto crítico: 0.2574898
- Criterio de decisión: Se rechaza H_0 si $T \in [0.2574898, \infty)$
- $p - value = 0.1260972$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distancia máxima absoluta observada no difiere significativamente de la curva acumulada esperada bajo un modelo teórico Log-Normal, lo que sugiere que la distribución Log-Normal podría ser adecuada para modelar el comportamiento general de las tasas de crecimiento del PIB.

Prueba de Anderson-Darling:

- Estadístico de prueba: 1.449299
- Punto crítico: 2.465673
- Criterio de decisión: Se rechaza H_0 si $T \in [2.465673, \infty)$
- $p - value = 0.050001$

Conclusión: No existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Dado que el estadístico de prueba no supera el punto crítico, se concluye que las discrepancias ponderadas en las colas de la distribución no son significativamente diferentes a las esperadas bajo un modelo Log-Normal, lo que refuerza la idoneidad de este modelo para las tasas de crecimiento del PIB.

Prueba de Shapiro-Wilk (Cuantiles Transformados):

- Estadístico de prueba: 0.8607213
- Punto crítico: 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.4047258$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distribución de los cuantiles inversos normales no difiere significativamente de la linealidad esperada bajo un modelo teórico Log-Normal, lo que significa que, bajo esta transformación, la distribución Log-Normal logra un ajuste aceptable.

B) Análisis Bajo la Distribución Teórica Weibull

Prueba Ji-Cuadrada de Pearson:

- Estadístico de prueba: 20.07786
- Punto crítico: 5.991465
- Criterio de decisión: Se rechaza H_0 si $T \in [5.991465, \infty)$
- $p - value = 4.36664 * 10^{-5}$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Esto indica que las frecuencias observadas de las tasas de crecimiento del PIB difieren significativamente de las frecuencias esperadas bajo un modelo teórico Weibull, lo que significa que, de manera global, la distribución no logra agrupar perfectamente el comportamiento de la variación del PIB en todos sus intervalos.

Prueba de Kolmogorov-Smirnov:

- Estadístico de prueba: 0.1791488
- Punto crítico: 0.2574898
- Criterio de decisión: Se rechaza H_0 si $T \in [0.2574898, \infty)$
- $p - value = 0.3835331$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distancia máxima absoluta observada no difiere significativamente de la curva acumulada esperada bajo un modelo teórico Weibull, lo que sugiere que la distribución Weibull podría ser una candidata adecuada para modelar el comportamiento general de las tasas de crecimiento del PIB.

Prueba de Anderson-Darling:

- Estadístico de prueba: 0.8930772
- Punto crítico: 2.465673
- Criterio de decisión: Se rechaza H_0 si $T \in [2.465673, \infty)$
- $p - value = 0.050001$

Conclusión: No existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Dado que el estadístico de prueba es inferior al punto crítico, se concluye que las discrepancias ponderadas en las colas de la distribución no son significativamente diferentes a las esperadas bajo un modelo Weibull, lo que indica que este modelo es robusto incluso en los extremos de la distribución de las tasas de crecimiento.

Prueba de Shapiro-Wilk (Cuantiles Transformados):

- Estadístico de prueba Z: 0.929886
- Punto crítico Z: 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.5232877$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distribución de los cuantiles inversos normales no difiere significativamente de la linealidad esperada bajo un modelo teórico Weibull, lo que significa que, bajo esta transformación, la distribución Weibull también logra un ajuste aceptable.

C) Análisis Bajo la Distribución Teórica Exponencial

Prueba de Lilliefors:

- Estadístico de prueba: 0.2320157
- Punto crítico: 0.2346497
- Criterio de decisión: Se rechaza H_0 si $T \in [0.2346497, \infty)$
- $p - value = 0.287678$

Conclusión: No existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Aunque el estadístico de prueba es alto, no supera el punto crítico. Por lo tanto, no se puede descartar formalmente que las tasas de crecimiento del PIB sigan un comportamiento Exponencial puro, aunque la evidencia sugiere que otros modelos (Log-Normal o Weibull) podrían ser más apropiados dado su desempeño en otras pruebas.

Tasa de Desempleo en Europa

1. Contexto:

El presente análisis se realiza utilizando datos oficiales de la Organización para la Cooperación y el Desarrollo Económicos (OCDE) sobre las tasas de desempleo armonizadas en países europeos. La variable bajo estudio es la tasa de desempleo como proporción de la fuerza laboral (población de 15 a 64 años, ambos sexos).

Se dispone de una muestra de tasas de desempleo expresadas en proporciones (valores entre 0 y 1), lo que hace natural evaluar el ajuste a distribuciones acotadas como la Beta, además de otras distribuciones de soporte positivo como la Log-Normal. El tamaño muestral es $n_4 = 37900$, tras un proceso de filtrado y limpieza de valores faltantes.



2. Pregunta de Investigación:


¿Existe suficiente evidencia estadística para determinar que la tasa de desempleo en los países europeos se comporta según un modelo teórico de distribución acotada, específicamente la distribución Beta, o si por el contrario se ajusta mejor a una distribución de soporte positivo como la Log-Normal, permitiendo al mismo tiempo descartar un comportamiento Exponencial puro?

3. Pruebas de Bondad de Ajuste Aplicadas:

- Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson
- Prueba de Lilliefors para exponencial
- Prueba de Kolmogorov-Smirnov (KS)
- Prueba de Anderson-Darling (AD)
- Prueba de Shapiro-Wilk (SW)

4. Graficos de apoyo:





5. Hipótesis Nula y Alternativa:

1. Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Beta con parámetros estimados.

2. Prueba de Lilliefors

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ es una exponencial con parámetro estimado.

3. Prueba de Kolmogorov-Smirnov

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Beta con parámetros estimados.

4. Prueba de Anderson-Darling

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal y Beta con parámetros estimados.

5. Prueba de Shapiro-Wilk

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ se distribuye de una $N(0,1)$ con datos escalados con distribución LogNormal y Beta con parámetros estimados.

6. Estadísticos de Prueba, Región de Rechazo y p-values

Para cada contraste se establece un nivel de significancia estándar $\alpha = 0.05$ (95% de confianza). La regla de decisión consiste en rechazar la hipótesis nula

(H_0) si el estadístico de prueba calculado supera el punto crítico teórico, o de manera equivalente, si el p-value es menor a 0.05.

A) Análisis Bajo la Distribución Teórica Log-Normal

Prueba Ji-Cuadrada de Pearson:

- Estadístico de prueba: 267.7031
- Punto crítico: 22.36203
- Criterio de decisión: Se rechaza H_0 si $T \in [22.36203, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Esto indica que las frecuencias observadas de las tasas de desempleo difieren significativamente de las frecuencias esperadas bajo un modelo teórico Log-Normal, lo que significa que, de manera global, la distribución Log-Normal no logra agrupar adecuadamente el comportamiento de las tasas de desempleo en todos sus intervalos.

Prueba de Kolmogorov-Smirnov:

- Estadístico de prueba: 0.01944979
- Punto crítico: 0.006261636
- Criterio de decisión: Se rechaza H_0 si $T \in [0.006261636, \infty)$
- $p - value = 6.947776 * 10^{-13}$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distancia máxima absoluta observada es significativamente mayor que la curva acumulada esperada bajo un modelo teórico Log-Normal, lo que refuerza que esta distribución no es adecuada para modelar las tasas de desempleo.

Prueba de Anderson-Darling:

- Estadístico de prueba: 26.36779
- Punto crítico: 2.453
- Criterio de decisión: Se rechaza H_0 si $T \in [2.453, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Dado que el estadístico de prueba supera ampliamente el punto crítico, se concluye que las discrepancias ponderadas en las colas de la distribución son significativamente diferentes a las esperadas bajo un modelo Log-Normal, lo que indica un pobre ajuste en los extremos de la distribución del desempleo.

Prueba de Shapiro-Wilk (Cuantiles Transformados):

- Estadístico de prueba : 0.9973372
- Punto crítico : 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.5074819$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que, bajo la transformación de cuantiles inversos normales, los datos no muestran una desviación significativa de la linealidad esperada para una distribución Log-Normal, lo cual es un resultado favorable para este modelo.

B) Análisis Bajo la Distribución Teórica Beta

Prueba Ji-Cuadrada de Pearson:

- Estadístico de prueba: 3486.868
- Punto crítico: 22.36203
- Criterio de decisión: Se rechaza H_0 si $T \in [22.36203, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Esto indica que las frecuencias observadas de las tasas de desempleo difieren significativamente de las frecuencias esperadas bajo un modelo teórico Beta, lo que significa que, de manera global, la distribución Beta no logra agrupar perfectamente el comportamiento de las tasas de desempleo en todos sus intervalos.

Prueba de Kolmogorov-Smirnov:

- Estadístico de prueba: 0.08258551
- Punto crítico: 0.006261636
- Criterio de decisión: Se rechaza H_0 si $T \in [0.006261636, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distancia máxima absoluta observada es considerablemente mayor que la curva acumulada esperada bajo un modelo teórico Beta, lo que sugiere que esta distribución tampoco captura adecuadamente el comportamiento general de las tasas de desempleo.

Prueba de Anderson-Darling:

- Estadístico de prueba: 546.1399
- Punto crítico: 2.453
- Criterio de decisión: Se rechaza H_0 si $T \in [2.453, \infty)$

- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. El estadístico de prueba es extremadamente superior al punto crítico, lo que indica que las discrepancias ponderadas en las colas de la distribución Beta son muy grandes, señalando un ajuste muy deficiente, especialmente en los valores extremos de la tasa de desempleo.

Prueba de Shapiro-Wilk (Cuantiles Transformados):

- Estadístico de prueba: 0.959375
- Punto crítico: 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.4886072$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que, bajo la transformación de cuantiles inversos normales, los datos no muestran una desviación significativa de la linealidad esperada para una distribución Beta, lo que sugiere que, desde la perspectiva de la prueba de Shapiro-Wilk, el ajuste podría considerarse aceptable.

C) Análisis Bajo la Distribución Teórica Exponencial

Prueba de Lilliefors:

- Estadístico de prueba: 0.2539896
- Punto crítico: 0.005523445
- Se rechaza H_0 si $T \in [0.005523445, \infty)$
- $p - value = 0$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. El estadístico de prueba supera drásticamente el punto crítico, por lo que se concluye firmemente que el supuesto de que las tasas de desempleo sigan un comportamiento Exponencial puro queda totalmente descartado para este conjunto de datos europeos.

Cargos por Seguro Médico en EE. UU.

1. Contexto:

El presente análisis se realiza utilizando una base de datos real sobre costos de seguros médicos individuales en Estados Unidos. La variable bajo estudio es el monto de los cargos médicos anuales (charges) facturados a los asegurados.

Se dispone de una muestra aleatoria independiente de cargos médicos, cuyos valores son positivos y presentan una asimetría característica de este tipo de

datos. El tamaño es $n = 1338$, tras un proceso de depuración de valores faltantes.


2. Pregunta de Investigación:

¿Existe suficiente evidencia estadística para determinar que los montos de cargos por seguro médico en Estados Unidos se comportan según un modelo teórico de distribución asimétrica de soporte positivo, específicamente la distribución Log-Normal, permitiendo al mismo tiempo descartar un comportamiento Exponencial puro?

3. Pruebas de Bondad de Ajuste Aplicadas:

- Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson
- Prueba de Lilliefors para exponencial
- Prueba de Kolmogorov-Smirnov (KS)
- Prueba de Anderson-Darling (AD)
- Prueba de Shapiro-Wilk (SW)

4. Gráficos de apoyo:



5. Hipótesis Nula y Alternativa:

1. Prueba de Bondad de Ajuste Ji-Cuadrada de Pearson

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal con parámetros estimados.

2. Prueba de Lilliefors

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ es una exponencial con parámetro estimado.

3. Prueba de Kolmogorov-Smirnov

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal con parámetros estimados.

4. Prueba de Anderson-Darling

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ propuestas son LogNormal con parámetros estimados.

5. Prueba de Shapiro-Wilk

$$H_0: F(x) = F^*(x) \text{ para todo } x \quad \text{vs} \quad H_a: F(x) \neq F^*(x) \text{ para algún } x$$

La $F(x)$ se distribuye de una $N(0,1)$ con datos escalados con distribución LogNormal con parámetros estimados.

6. Estadísticos de Prueba, Región de Rechazo y p-values

Para cada contraste se establece un nivel de significancia estándar $\alpha = 0.05$ (95% de confianza). La regla de decisión consiste en rechazar la hipótesis nula (H_0) si el estadístico de prueba calculado supera el punto crítico teórico, o de manera equivalente, si el p-value es menor a 0.05.

A) Análisis Bajo la Distribución Teórica Log-Normal

Prueba Ji-Cuadrada de Pearson:

- Estadístico de prueba: 79.61182
- Punto crítico: 15.50731
- Criterio de decisión: Se rechaza H_0 si $T \in [15.50731, \infty)$
- $p - \text{value} = 5.850875 * 10^{-14}$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Esto indica que las frecuencias observadas de los cargos médicos difieren significativamente de las frecuencias esperadas bajo un modelo teórico Log-Normal, lo que significa que, de manera global, la distribución Log-Normal no logra agrupar perfectamente el comportamiento de los montos de seguro en todos sus intervalos.

Prueba de Kolmogorov-Smirnov:

- Estadístico de prueba: 0.0365844
- Punto crítico: 0.03320952
- Criterio de decisión: Se rechaza H_0 si $T \in [0.03320952, \infty)$
- $p - value = 0.053439$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Aunque el estadístico de prueba supera ligeramente el punto crítico, el p-value es mayor a 0.05, lo que indica que la distancia máxima absoluta observada no difiere significativamente de la curva acumulada esperada bajo un modelo teórico Log-Normal. Esto sugiere que, desde una perspectiva global acumulada, la distribución Log-Normal podría ser adecuada.

Prueba de Anderson-Darling:

- Estadístico de prueba: 3.944712
- Punto crítico: 2.467591
- Criterio de decisión: Se rechaza H_0 si $T \in [2.467591, \infty)$
- $p - value = 0.499999$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Dado que el estadístico de prueba supera el punto crítico, se concluye que las discrepancias ponderadas en las colas de la distribución son significativamente diferentes a las esperadas bajo un modelo Log-Normal. Esto indica que, aunque el ajuste global pueda ser aceptable según KS, el comportamiento en los extremos (montos muy bajos o muy altos) presenta desviaciones importantes.

- **Prueba de Shapiro-Wilk (Cuantiles Transformados):**

- Estadístico de prueba: 0.9840405
- Punto crítico: 1.644854
- Criterio de decisión: Se rechaza H_0 si $T \in [1.644854, \infty)$
- $p - value = 0.5095108$

Conclusión: No existe evidencia estadística suficiente, con un nivel de significancia del 5%, para rechazar la hipótesis nula. Esto indica que la distribución de los cuantiles inversos normales no difiere significativamente de la linealidad esperada bajo un modelo teórico Log-Normal, lo que significa que, bajo esta transformación, la distribución Log-Normal logra un ajuste aceptable.

B) Análisis Bajo la Distribución Teórica Exponencial

Prueba de Lilliefors:

- Estadístico de prueba: 0.09614826

- Punto crítico: 0.0293969
- Criterio de decisión: Se rechaza H_0 si $T \in [0.0293969, \infty)$
- $p - value = 0.0004364922$

Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. El estadístico de prueba supera el punto crítico, por lo que se concluye que el supuesto de que los cargos por seguro médico sigan un comportamiento Exponencial puro queda descartado para este conjunto de datos. Esto era esperable, dado que la distribución Exponencial no captura la asimetría y la cola pesada característica de los costos médicos.

Detección de Fraude

1. Contexto del Problema:

Se dispone de una base de datos que contiene información sobre 100,000 transacciones comerciales. Para cada transacción, se registra dos variables categóricas: el tipo de dispositivo desde el cual se realizó la compra (Computadora, Celular o Tablet) y si la transacción fue marcada como fraudulenta o no (Sí es Fraude / No es Fraude).

2. Pregunta de Investigación:

¿Existe suficiente evidencia estadística para afirmar que la probabilidad de que una transacción sea fraudulenta depende del tipo de dispositivo (computadora, celular o tablet) utilizado por el cliente?

3. Planteamiento de Hipótesis:

$$H_0: P(I = i, J = j) = P(I = i)P(J = j), \forall i, j \quad \text{vs}$$

$$H_a: P(I = i, J = j) \neq P(I = i)P(J = j) \text{ para algún } i, j$$

4. Metodología:

Para contrastar las hipótesis, se aplicó la Prueba Ji-Cuadrada de Independencia de Pearson para una tabla de contingencia de 3 filas (tipo de dispositivo) por 2 columnas (condición de fraude). Se estableció un nivel de significancia $\alpha = 0.05$.

5. Tablas de Frecuencias:

A continuación, se presentan tablas de la creación de la tabla de contingencia.

Tabla 1. Frecuencias Observadas (Casos Reales)

Tipo de Dispositivo	No es Fraude	Sí es Fraude	Total
---------------------	--------------	--------------	-------

Computadora	18,334	14,950	33,284
Celular	16,081	17,373	33,454
Tablet	18,077	15,185	33,262
Total	52,492	47,508	100,000

Tabla 2. Frecuencias Esperadas (Bajo el supuesto de Independencia)

Tipo de Dispositivo	No es Fraude	Sí es Fraude
Computadora	17,471.44	15,812.56
Celular	17,560.67	15,893.33
Tablet	17,459.89	15,802.11


6. Resultados de la Prueba Estadística:

- Estadístico de prueba (Ji-Cuadrada calculada): 397.9842
- Grados de libertad (gl): $(3 - 1) * (2 - 1) = 2$
- Valor crítico (Punto crítico): 5.991465
- P-Valor: $3.791596 * 10^{-87}$

7. Regla de Decisión y Conclusión:

Dado un nivel de significancia $\alpha = 0.05$, se rechaza la hipótesis nula si:

$$T \in [5.991465, \infty)$$



Conclusión:

Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula. Por lo tanto, se concluye que el tipo de dispositivo utilizado por

el cliente Sí está relacionado con la ocurrencia de fraude. El análisis revela un patrón claro donde los dispositivos móviles (celulares) presentan una frecuencia de fraude observada (17,373) superior a la esperada (15,893.33), mientras que las computadoras y tablets muestran frecuencias de fraude observadas inferiores a las esperadas.

AUDITORÍA BANCARIA: RIESGO DE ABANDONO POR PAÍS

1. Contexto del Problema:

Se dispone de una base de datos que contiene información sobre clientes de un banco. Para cada cliente, se registran dos variables categóricas: el país de residencia (Francia, Alemania o España) y si el cliente ha abandonado el banco (Cliente Perdido / Churn) o continúa como cliente fiel (Cliente Fiel / Se queda).

2. Pregunta de Investigación:

¿Existe suficiente evidencia estadística para afirmar que la probabilidad de que un cliente abandone el banco (churn) depende del país de residencia (Francia, Alemania o España)?

3. Planteamiento de Hipótesis:

$H_0: P(I = i, J = j) = P(I = i)P(J = j), \forall i, j \quad vs$

$H_a: P(I = i, J = j) \neq P(I = i)P(J = j) \text{ para algún } i, j$

4. Metodología:

Para contrastar las hipótesis, se aplicó la Prueba Ji-Cuadrada de Independencia de Pearson para una tabla de contingencia de 3 filas (país de residencia) por 2 columnas (condición de abandono).

5. Tablas de Frecuencias:

A continuación, se presentan tablas de construcción de la tabla de contingencia.

Tabla 1. Frecuencias Observadas (Casos Reales)

País de Residencia	Cliente Fiel (Se queda)	Cliente Perdido (Churn)	Total
Francia (France)	4,204	810	5,014
Alemania (Germany)	1,695	814	2,509
España (Spain)	2,064	413	2,477
Total	7,963	2,037	10,000

Tabla 2. Frecuencias Esperadas

País de Residencia	Cliente Fiel (Se queda)	Cliente Perdido (Churn)
Francia (France)	3,992.65	1,021.35
Alemania (Germany)	1,997.92	511.08
España (Spain)	1,972.44	504.56


6. Resultados de la Prueba Estadística:

- Estadístico de prueba (T): 301.2553
- Grados de libertad (v): $(r - 1) * (c - 1) = (3 - 1) * (2 - 1) = 2$
- Valor crítico : 5.991465
- $P_valor = 3.830318 * 10^{-66}$

7. Regla de Decisión y Conclusión:

Dado un nivel de significancia $\alpha = 0.05$, se rechaza la hipótesis nula si:

$$T \in [5.991465, \infty)$$



Conclusión: Existe evidencia estadística suficiente, con una confianza del 95%, para rechazar la hipótesis nula, para concluir que las variables "país de residencia" y "abandono bancario" no son independientes. Por lo tanto, el país donde reside el cliente SÍ influye en la decisión de abandonar el banco.

Salud Mental: Estrés según Modalidad de Trabajo

1. Contexto del Problema:

Se dispone de una base de datos que contiene información sobre 150,000 empleados del sector tecnológico. Para cada empleado, se registran dos

variables: la modalidad de trabajo (Remoto, Híbrido o Presencial) y su nivel de estrés laboral medido en una escala continua.

2. Pregunta de Investigación:

¿Existe suficiente evidencia estadística para afirmar que la distribución de los niveles de estrés laboral es diferente entre los empleados que trabajan en modalidad Remota, Híbrida y Presencial?

3. Planteamiento de Hipótesis:

Sean $F_1(x)$, $F_2(x)$ y $F_3(x)$ las funciones de distribución acumulada del nivel de estrés para las poblaciones de empleados en modalidad Remota, Híbrida y Presencial, respectivamente.

$H_0: F_1(x) = F_2(x) = F_3(x), \forall x \text{ vs}$

$H_a: \text{Al menos una dist. tiene mayores observaciones}$

4. Metodología:

Para contrastar las hipótesis, se aplicó la Prueba de Kruskal-Wallis. Esta prueba se basa en los rangos (posiciones) asignados a todas las observaciones combinadas. Se estableció un nivel de significancia $\alpha = 0.05$.

5. Estadísticos Descriptivos por Grupo:

A continuación, se presentan los tamaños muestrales y las sumas de rangos obtenidas para cada modalidad de trabajo.

Tabla 1. Tamaños muestrales por modalidad de trabajo

Modalidad de Trabajo	Número de Empleados (n)
Remoto	52,471
Híbrido	60,056
Presencial	37,473
Total	150,000

Tabla 2. Suma de rangos por modalidad de trabajo

Modalidad de Trabajo	Suma de Rangos (R _i)
Remoto	3,934,842,303
Híbrido	4,501,063,623
Presencial	2,814,169,075


6. Resultados de la Prueba Estadística:

- Estadístico de prueba: 0.2839225
- Grados de libertad (v): $k - 1 = 3 - 1 = 2$
- Valor crítico : 5.991465
- P-Value: 0.8676549

7. Regla de Decisión y Conclusión:

Dado un nivel de significancia $\alpha = 0.05$, se rechaza la hipótesis nula si

$$T \in [5.991465, \infty)$$



Conclusión:

No existe evidencia estadística suficiente para rechazar la hipótesis nula, con una confianza del 95%, para concluir que las distribuciones de los niveles de estrés difieren entre las tres modalidades de trabajo (Remoto, Híbrido y Presencial).

Correlación entre Ingresos y Deuda

1. Contexto del Problema:

Se dispone de una base de datos que contiene información financiera de 92,081 clientes. Para cada cliente, se registran dos variables cuantitativas continuas: el ingreso anual (Annual_Income) y la deuda pendiente (Outstanding_Debt).

2. Pregunta de Investigación:

¿Existe suficiente evidencia estadística para afirmar que existe una asociación monótona (creciente o decreciente) entre el orden de los ingresos y el orden de las deudas de los clientes? Es decir, ¿los clientes con mayores ingresos tienden a ocupar posiciones diferentes en el ranking de deudas en comparación con aquellos de menores ingresos?

3. Planteamiento de Hipótesis:

Sea $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ una muestra aleatoria de pares de observaciones de las variables continuas X (ingreso anual) e Y (deuda pendiente). Sea ρ_s el coeficiente de correlación de Spearman para la población.

$$H_0: \rho_s = 0 \text{ vs } H_a: \rho_s \neq 0$$

4. Metodología:

Para contrastar las hipótesis, se aplicó el coeficiente de correlación de rangos de Spearman. Este método no paramétrico asigna rangos a cada observación dentro de su respectiva variable, y calcula la correlación de Pearson sobre esos rangos. Para evaluar significancia estadística en muestras grandes ($n > 30$), se utilizó la transformación al estadístico t de Student con $(n - 2)$ grados de libertad. Se estableció un nivel de significancia $\alpha = 0.05$ para una prueba de dos colas.

5. Estadísticos:

A continuación, se presentan los estadísticos descriptivos del análisis.

Estadístico	Valor
Número total de clientes analizados (n)	92,081
Suma de diferencias de rangos al cuadrado	1.653115×10^{14}


6. Resultados de la Prueba Estadística:

Estadístico	Valor
Coeficiente de Spearman (r_s)	-0.2704113
Estadístico t calculado	-85.23029
Valor t crítico ($\alpha = 0.05$, dos colas)	± 1.95999
Grados de libertad (v)	$n - 2 = 92,079$

7. Regla de Decisión y Conclusión:

Dado un nivel de significancia $\alpha = 0.05$ para una prueba de dos colas, se rechaza la hipótesis nula si:

$$T \in (-\infty, -1.95999] \cup [1.95999, \infty)$$



Conclusión:

Existe evidencia estadística suficiente para rechazar la hipótesis nula, con una confianza del 95%, para concluir que existe una asociación monótona entre el ingreso anual y la deuda pendiente de los clientes.

Análisis Educativo

1. Contexto del Problema:

Se dispone de una base de datos que contiene las calificaciones de 395 estudiantes en dos momentos distintos: primer periodo (G1) y periodo final (G3). Para cada estudiante, se registran ambas calificaciones. El objetivo es determinar si existe evidencia estadística de que las calificaciones cambiaron significativamente entre ambos periodos, ya sea de forma positiva (mejora) o negativa (empeoramiento).

2. Pregunta de Investigación:

¿Existe suficiente evidencia estadística para afirmar que las calificaciones de los estudiantes en el periodo final son diferentes a las calificaciones del primer periodo? Es decir, ¿la mediana de las diferencias (G3 - G1) es distinta de cero?

3. Planteamiento de Hipótesis:

Sean $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ una muestra aleatoria de pares de observaciones de variables aleatorias continuas, donde X_i representa la calificación del i-ésimo estudiante en el primer periodo (G1) e Y_i representa la calificación del mismo estudiante en el periodo final (G3).

Definimos la variable aleatoria $D = Y - X$, y $d_{0.5}$ como la mediana poblacional

$$H_0: P(d_{0.5} > 0) = P(d_{0.5} < 0) = 0.5 \quad \text{vs} \quad H_0: P(d_{0.5} > 0) \neq P(d_{0.5} < 0)$$

4. Estadísticos:

A continuación, se presentan los estadísticos descriptivos del análisis.

Estadístico	Valor
Total de estudiantes analizados (n total)	395
Estudiantes sin cambio (diferencia = 0)	93
Estudiantes con cambio (diferencia $\neq$ 0, n')	302
Estudiantes que mejoraron (diferencia > 0)	143
Estudiantes que empeoraron (diferencia < 0)	159
Suma de rangos positivos (T^+)	21,378.5
Suma de rangos negativos (T^-)	24,374.5
Estadístico $W = \min(T^+, T^-)$	21,378.5

6. Resultados de la Prueba Estadística:


A continuación, se presentan los estadísticos de prueba calculados y los parámetros de decisión.

Estadístico	Valor
Media esperada bajo H_0 (μ_W)	22,876.5
Desviación estándar esperada (σ_W)	1,518.787
Estadístico Z calculado	-0.9863135
Valor crítico Z ($\alpha = 0.05$, dos colas)	± 1.96
P-Valor (bilateral) = $2 \times P(Z \leq -0.9863 \mid H_0)$	0.3239793

7. Regla de Decisión y Conclusión:

Dado un nivel de significancia $\alpha = 0.05$ para una prueba de dos colas, se rechaza la hipótesis nula si:

$$Z \in (-\infty, -1.96) \cup (1.96, \infty)$$



Conclusión:

No existe evidencia estadística suficiente para no rechaza la hipótesis nula, con una confianza del 95%, para concluir que la mediana poblacional de las diferencias ($G3 - G1$) sea diferente de cero.

Anexos

Simulación por el método de Monte-Carlo:

```
# =====
# 1. SIMULACIÓN DE ANDERSON-DARLING (PARA ENCONTRAR VALORES CRÍTICOS)
# =====
m <- 10000
n_real <- 37900

j_vec <- 1:n_real
coeficiente <- (2 * j_vec - 1) / n_real

# Vector para almacenar los estadísticos de las 10000 simulaciones
A <- numeric(m)

for(i in 1:m){
  # 1. Generar y ordenar la muestra de una uniforme(0,1)
  ur <- sort(runif(n_real, 0, 1))

  # 2. Cálculo vectorizado rápido de la sumatoria
  s <- sum(coeficiente * (log(ur) + log(1 - ur[n_real - j_vec + 1])))

  # Guardamos el estadístico final de la simulación i
  A[i] <- -n_real - s
}

# =====
# OBTENCIÓN DE LOS CUANTILES / REGION DE RECHAZO
# =====
cuantiles_ad <- quantile(A, c(0.900, 0.95, 0.975, 0.990))

# =====
# CÁLCULO DEL P-VALUE EMPÍRICO BASADO EN LA SIMULACIÓN
# =====

p_val_ad_w1 <- sum(A >= 2.467591) / m
p_val_ad_g1 <- sum(A >= 2.465673) / m
```

Del libro de Goodnes of Fit Techniques, en la página 123 (Como justificación de la forma del calculo de algunas regiones de rechazo

TABLE 4.7 Modifications and Percentage Points for a Test for Normality with μ and σ^2 Unknown
(Section 4.8.1, Case 3)

		Significance level α							
Statistic	Modified statistic	.50	.25	.15	.10	.05	.025	.01	.005
<u>Upper tail</u>									
D	$D(\sqrt{n} - 0.01 + 0.85/\sqrt{n})$		-	0.775	0.819	0.895	0.995	1.035	
V	$V(\sqrt{n} + 0.05 + 0.82/\sqrt{n})$		-	1.320	1.386	1.489	1.585	1.693	
W ²	$W^2(1.0 + 0.5/n)$	.051	.074	.091	.104	.126	.148	.179	.201
U ²	$U^2(1.0 + 0.5/n)$	.048	.070	.085	.096	.117	.136	.164	.183
A ²	$A^2(1.0 + 0.75/n + 2.25/n^2)$	.341	.470	.561	.631	.752	.873	1.035	1.159
<u>Lower tail</u>									
W ²	$W^2(1.0 + 0.5/n)$	.051	.036	.029	.026	.022	.019	.017	
U ²	$U^2(1.0 + 0.5/n)$	.048	.033	.027	.025	.021	.018	.016	
A ²	$A^2(1.0 + 0.75/n + 2.25/n^2)$	.341	.249	.226	.188	.160	.139	.119	

Adapted, with additions, from Table 54 of Pearson and Hartley (1972) and from Stephens (1974b), with permission of the Biometrika Trustees and of the American Statistical Association.

